

基于图神经网络的 自校准多摄像头多目标跟踪方法

DyGLIP 基线 · 算法与数据完整报告

复现 · 数据分布 · 双卡训练 · 评测 · 图像证据

评测集: WildTrack 全量 (7 摄 · 41,499 检测框)

基线锚点: Quach et al., DyGLIP, CVPR 2021 | 报告日期: 2026-09-18

1. 概述

0.9174

eval AUC

41,499

检测框数

7

摄像头

313

全局身份

200

训练 epoch

本报告将 **DyGLIP** (Dynamic Graph Link Prediction for Multi-Camera Multi-Object Tracking, CVPR 2021) 作为课题「基于图神经网络的自校准多摄像头多目标跟踪方法」的强基线，用 **PyTorch** 逐模块重写，并在配置驱动、多卡并行的工程化框架下完成端到端训练与评测。DyGLIP 原始官方实现基于 Python 2.7 + TensorFlow 1.11，无法在当前 torch 2.x / py3.11 环境运行，因此本工作做了忠实重写与工程化（模型参数量 135,808）。

1.1 数据集角色

- **WildTrack**: 全量 7 摄 / 401 帧，含全局 personID 真值（313 个身份）与完整标定 → **评测集**。
- **EPFL**: 30 段视频（2.4 GB），含 GT 与标定 → 自监督训练候选。

1.2 关键结果一览

表 1 DyGLIP 基线关键结果（WildTrack 全量）

指标	值	说明
模型参数	135,808	SAL + TAL + 链路预测头
训练硬件	2 × RTX 4090	DDP over windows 并行
训练	200 epochs / 163.8s	loss 2.71 → 1.78
eval AUC	0.9174	链路预测排序质量（398 窗口均分）
pos_acc / neg_acc	0.9999 / 0.471	固定阈值导致的负类误判
pairwise-F1	0.0854	聚类需 OT / 全局匹配

核心洞察：DyGLIP 能学到高质量的同身份节点排序（子集 AUC $\approx$ 0.98），但固定 0 阈值把约 33% 的负对误判为正，导致 neg_acc $\approx$ 0.47。这一结构性短板正是本课题引入 Sinkhorn / 最优传输全局匹配的动机所在。

2. 数据与数据分布（一）

2.1 数据集可用性

表 2 数据集本地可用性核查

数据集	规模	用途	状态
WildTrack	7 摄 × 401 帧 / 400 帧标注 / 21 标定 XML	评测（有 GT）	✓ 本地完整
EPFL	30 AVI（2.4 GB） / GT + 标定	训练（自监督）	✓ 本地完整

2.2 数据获取说明

WildTrack 官方 62 GB 直链在 EPFL 端损坏（EOCD 中央目录指针偏移 2^{32} ，含 1101 个坏条目），已弃用；改由 Kaggle 镜像 [aryashah2k/large-scale-multicamera-detection-dataset](#)（CC0-1.0，约 10 GB）获取，解压后逐帧校验通过（图像读取 100% 成功，无缺失）。

2.3 每摄检测框分布




图 4 每摄检测框总数（实测统计）：C6=9,029 最高；C4=2,178 最低；合计 41,499

从 400 帧标注解析，得到各摄行人框数：C1=8,506、C2=7,752、C3=6,703、C4=2,178、C5=3,701、C6=9,029、C7=3,630。检测框总量 **41,499**，唯一跨摄全局 personID 共 **313** 个。

2.4 每摄密度差异




图 5 各摄平均单帧行人密度: C6 ≈ 22.6 最高, C4 ≈ 5.4 最低 (约 4 倍差异)

各摄平均单帧检测密度差异显著 (约 4 倍), 反映遮挡、场景密集度差异, 是检验跨摄鲁棒性的自然压力。

3. 数据与数据分布 (二)

3.1 身份出现时长分布 (长尾)




图 6 每位全局身份出现的 (时间槽) 窗口数: 长尾分布, 多数身份只覆盖少量窗口

313 个全局身份中，绝大多数只覆盖少数时间窗口（长尾）。这对时序图建模提出挑战：罕见身份的正样本极少，需要窗口内 / 跨摄的时间注意力来聚合证据。

3.2 ReID 特征性质




图 7 ReID 特征：512 维，L2 范数 ≈ 1.0 (OSNet x1.0, 官方 Duke 权重提取)

reid_feats.pkl 共 41,499 个 box，特征维度 512，L2 归一化后范数为 1.0。提取器复用论文官方 Step1 的 OSNet (Duke 预训练)，保证与论文同源可比。

4. 算法结构

4.1 数据流

ReID(512) $\rightarrow$ 建图 (节点=(摄像头, tracklet, 时间槽), 同 tracklet 两两连边) $\rightarrow$ 滑窗 (每窗口 $T=3$ 快照) $\rightarrow$ **SAL** 空间注意力 $\rightarrow$ **TAL** 时间注意力 $\rightarrow$ Embedding[N,T,F] $\rightarrow$ 链路预测 logits。标签由「同身份成团」自监督产生，无需跨摄人工真值。

4.2 模块

- **SAL (结构注意力)**：head config [16,8,8]，隐层 128；对孤点退化为自环保证数值稳定。
- **TAL (时间注意力)**：head 16，因果 mask (tril)；仅用过去快照预测当前。
- **损失** = 链路预测 BCE + 0.5 $\cdot$ 结构注意力 L2；优化器 Adam 分组 weight-decay, lr=1e-3。

4.3 实时指标定义 (每 epoch)

表 3 训练实时上报指标

指标	定义
loss	= graph_loss + reg_loss
graph_loss	链路预测主损失 (BCE)
reg_loss	结构注意力权重 L2 正则
pos_acc	正对判「相似」比例 (score > 0)
neg_acc	负对判「不相似」比例 (score < 0)
acc	平衡准确率 = $0.5 \times (\text{pos} + \text{neg})$

5. 训练配置与损失曲线

5.1 训练配置（复现关键）

表 4 训练超参数

项	值
输入特征	512 维 L2 归一化 ReID
窗口	T=3 (滑窗)
epochs / seed	200 / 7
硬件	2 × RTX 4090
并行	DDP over windows (w % 2 == rank 分片, 梯度 all-reduce)
accumulate	2 (梯度累积)
优化器	Adam, lr=1e-3, wd=5e-4, grad-clip=1.0
neg_weight / 负采样	0.5 / 度分布负采样 (distortion=0.75)

5.2 训练损失




图 1 训练损失: total 2.71 → 1.78; graph_loss 2.60 → 1.74; reg_loss 0.11 → 0.038

双卡并行下 200 epochs 稳定收敛，耗时约 163.8 s。graph_loss 为主损失，reg_loss 由结构注意力的 L2 权重提供正则。

6. 实时准确率与阈值分析

6.1 实时 accuracy 曲线




图 2 实时 accuracy: pos_acc ≈ 0.9999 , neg_acc ≈ 0.471 , 平衡 acc ≈ 0.736

6.2 正 / 负对分数分布 (根因)




图 3 分数分布: 正对均值 +2.67 (100% > 0) ; 负对均值 -0.33 (33% > 0) ; 子集 AUC ≈ 0.98

关键结论：正、负对整体可分，说明模型排序能力很强；但负对均值只到 -0.33，仍有约 1/3 落在线性阈值 0 之上被误判为正。因此 $\text{neg_acc} \approx 0.47$ 并非模型容量不足，而是阈值标定（threshold calibration）问题——固定 0 阈值偏置判正。

7. 评测结果与课题对照

7.1 评测

表 5 WildTrack 评测结果

指标	值	备注
eval AUC_mean	0.9174	398 窗口均分，排序质量
AUC_std	0.0506	各窗口差异
pairwise-F1	0.0854	ID 聚类阈值敏感

7.2 对课题创新点的对照

表 6 DyGLIP 基线 vs 本课题方向

维度	DyGLIP（本基线）	本课题
图类型	同质图（仅 tracklet 节点）	异质图（Tracklet + Camera）
摄像头	仅 positional encoding	Camera 节点注入拓扑
空间先验	无	CTPM（摄像头转移概率）
匹配	链路预测固定阈值 → 阈值敏感	Sinkhorn / dustbin OT 全局约束
标定	不需要	自校准

报告的 $\text{neg_acc} \approx 0.47$ 与 33% 负对误判，正是「链路预测 + 固定阈值」在多摄关联上的量化短板。本课题以 Sinkhorn 最优传输做全局一对一匹配（对偶约束、阈值无关、优选浓度对），可针对性地提升负类抑制与聚类纯度。

8. 复现命令与状态

8.1 复现命令

```
cd code
# 全量特征提取 (OSNet 官方权重, 7 摄)
../.venv-train/bin/python scripts/prepare_wildtrack.py \
  --config configs/base.yaml configs/wildtrack_eval.yaml \
  --override data.wildtrack.cameras=C1,C2,C3,C4,C5,C6,C7 data.wildtrack.frames=400

# 双卡训练 (200 epochs)
```

```

../.venv-train/bin/python scripts/train.py \
  --config configs/base.yaml configs/wildtrack_eval.yaml \
  --override paths.reid_feats=files/datasets/WildTrack/reid_feats.pkl \
  trainer.epochs=200 trainer.world_size=2 trainer.first_gpu=0 trainer.accumulate=2 \
  misc.seed=7 misc.checkpoint_every_n_epochs=50

# 评测
../.venv-train/bin/python scripts/evaluate.py \
  --config configs/base.yaml configs/wildtrack_eval.yaml \
  --override paths.reid_feats=files/datasets/WildTrack/reid_feats.pkl \
  --ckpt runs/<时间戳>-7/model.pt --gpu 0

```

8.2 状态与下一步

- ✓ WildTrack 全量特征提取 ($41,499 \times 512$) ; ✓ 双卡 DDP 训练框架; ✓ 200 epochs, eval AUC = 0.9174
- ✓ 训练曲线 / accuracy / 分数分布图证据
- ○ hetero-CTPM 异质图分支 + Sinkhorn/OT 匹配 (消融对标)
- ○ EPFL 自监督训练 + 跨数据集评测